

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«САНКТ-ПЕТЕРБУРГСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
ПЕТРА ВЕЛИКОГО»

Институт компьютерных наук и кибербезопасности

Отчет о прохождении производственной (технологической (проектно-технологической)) практики

Чичкан Елизавета Владимировна

(Ф.И.О. обучающегося)

3 курс, 5130203/30101

(номер курса обучения и учебной группы)

02.03.03 Математическое обеспечение и администрирование информационных систем

(направление подготовки (код и наименование))

Место прохождения практики: АО НПП «Интеграл-В»

(указывается наименование профильной организации или наименование структурного подразделения)

г. Санкт-Петербург, ул. Академика Павлова 14д

ФГАОУ ВО «СПбПУ», фактический адрес)

Сроки практики: с 15.06.2026 по 11.07.2026

Руководитель практической подготовки от ФГАОУ ВО «СПбПУ»: Пак Вадим Геннадьевич, к.ф.-м.н., доцент ВШТИИ

(Ф.И.О., уч. степень, должность)

Консультант практической подготовки от ФГАОУ ВО «СПбПУ»: нет

(Ф.И.О., уч. степень, должность)

Руководитель практической подготовки от профильной организации: Захарченко Владимир Сергеевич, главный специалист машинного обучения нейронных сетей АО НПП «Интеграл-В»

Оценка: отлично

Руководитель практической подготовки от ФГАОУ ВО «СПбПУ»:

Руководитель практической подготовки от профильной организации:

Обучающийся:

Дата: 11.07.26



СОДЕРЖАНИЕ

ВВЕДЕНИЕ	4
ГЛАВА 1. ТЕОРЕТИЧЕСКИЕ ОСНОВЫ И АНАЛИЗ МЕТОДОВ ПОСТРОЕНИЯ КАРТ ГЛУБИН.....	6
1.1. Постановка задачи трехмерной реконструкции	6
1.1.1. Многоакурные подходы и Structure from Motion (SfM)	6
1.1.2. Монокулярные подходы на базе глубокого обучения	6
1.2. Сравнительный анализ современных моделей карт глубин.....	7
1.2.1. Модель COLMAP	7
1.2.2. Модель DepthNet	7
1.2.3. Модель MiDaS	8
1.2.4. Модель Depth Anything v2.....	8
1.2.5. Модель DINOv3.....	8
1.2.6. Выбор модели для реализации.....	9
1.3. Обоснование выбора технологического стека	10
ГЛАВА 2. ПРОЕКТИРОВАНИЕ И ПРОГРАММНАЯ РЕАЛИЗАЦИЯ СИСТЕМЫ ПОСТРОЕНИЯ КАРТ ГЛУБИН	10
2.1. Формулирование требований к веб-приложению и определение его архитектуры	10
2.2. Разработка веб-приложения и программная реализация модели	11
2.3. Инженерная отладка и сборка Docker-контейнера.....	11
2.4. Выводы по главе.....	11
ГЛАВА 3. ЭКСПЕРИМЕНТАЛЬНОЕ ИССЛЕДОВАНИЕ И АНАЛИЗ РЕЗУЛЬТАТОВ РАБОТЫ МОДЕЛИ	12
3.1. Методика проведения экспериментов и метрики оценки.....	12
3.1.1. Референсные метрики качества	12

3.1.2. Безреференсные метрики качества.....	12
3.1.3. Программные метрики.....	13
3.2. Анализ влияния конфигураций модели	14
3.2.1. Анализ производительности	15
3.2.2. Анализ качества.....	17
3.3. Исследование зависимости эффективности от параметров входного видеопотока	18
3.3.1. Влияние цветowych карт на скорость обработки.....	18
3.3.2. Влияние разрешения и сжатия кадра	22
3.3.3. Выводы	27
3.4. Оценка стабильности модели на различных типах сцен	28
ЗАКЛЮЧЕНИЕ	30
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	31

ВВЕДЕНИЕ

Современные интеллектуальные системы ежедневно обрабатывают колоссальные объёмы визуальных данных, где видеоконтент лидирует. В робототехнике, беспилотном транспорте, видеонаблюдении и AR критически важна пространственная оценка окружения. Извлечение 3D-структуры из 2D-изображений традиционно требовало сложного многоракурсного оборудования или больших вычислительных затрат на фотограмметрию. В этих условиях растёт роль подходов на базе глубокого обучения для монокулярной оценки глубины, позволяющих оперативно восстанавливать объёмные характеристики сцены и строить карты глубин по стандартному видеопотоку. Это оптимизирует постобработку и повышает автономность интеллектуальных систем [1].

Разработка эффективных моделей построения карт глубин с использованием ИИ — высокотехнологичная и востребованная инженерная задача. Особенно актуально создание готовых программных решений в виде компактных, платформонезависимых веб-приложений и контейнеризированных модулей для внедрения в производственные пайплайны и смежные системы анализа видеоданных.

Целью данной практики является исследование и сравнительный анализ современных методов построения карт глубин, а также их программная реализация в виде веб-приложения, позволяющего автоматически обрабатывать видеопотоки и визуализировать результаты.

Для достижения поставленной цели были сформулированы и решены следующие задачи:

1. Изучить современные методы построения карт глубин (DepthNet, Depth Anything v2, DINOv3, COLMAP, MiDaS) и выполнить обоснованный выбор базовых моделей для интеграции в веб-приложение;
2. Сформулировать функциональные и нефункциональные требования к проектируемому веб-приложению, определить архитектуру системы и выполнить обоснованный выбор технологического стека (Python 3.10, Gradio 5.38.0, Docker) для реализации;

3. Разработать программный интерфейс веб-приложения, обеспечивающий загрузку исходного видео, его обработку с применением выбранного ИИ-алгоритма, визуализацию итоговых карт глубин, а также сохранение и скачивание обработанных материалов;
4. Выполнить программную реализацию и интеграцию выбранной ИИ-модели для корректного построения пространственной структуры видеокадров;
5. Провести комплексное тестирование разработанного приложения на различных типах видеоматериалов, осуществить отладку, оптимизацию производительности и сборку Docker-контейнера.

Таким образом, в рамках данной практики планируется программная реализация готового к развертыванию прототипа интеллектуальной системы анализа видео, а также углубленное изучение и практическое освоение современных архитектур глубокого обучения в области компьютерного зрения.

ГЛАВА 1. ТЕОРЕТИЧЕСКИЕ ОСНОВЫ И АНАЛИЗ МЕТОДОВ ПОСТРОЕНИЯ КАРТ ГЛУБИН

1.1. Постановка задачи трехмерной реконструкции

Задача 3D-реконструкции заключается в математическом восстановлении пространственной структуры сцены (координат X , Y , Z и геометрии поверхностей) по двумерным данным — статическому кадру или видеопотоку. Результатом работы алгоритмов является карта глубин, связывающая каждый пиксель с расстоянием до объекта. В зависимости от входных данных и математического аппарата подходы к построению карт глубин делятся на многоракурсные (фотограмметрия, Structure from Motion) и монокулярные (по одиночному кадру).

1.1.1. Многоракурсные подходы и Structure from Motion (SfM)

Классический подход Structure from Motion (SfM) базируется на расчете сдвига пикселей между кадрами (параллакса) при перемещении точки наблюдения. Пайплайн SfM включает четыре шага: последовательный сбор кадров с взаимным перекрытием 60-80%, физическое перемещение камеры, сопоставление ключевых точек алгоритмами и финальную триангуляцию с оптимизацией ошибки перепроецирования для расчета 3D-координат.

Главные достоинства метода — высокая геометрическая точность и возможность получения абсолютной метрической глубины без искажений. Однако SfM имеет высокую вычислительную сложность, критически чувствителен к движущимся объектам в кадре и теряет эффективность на нетекстурированных или однотонных поверхностях.

1.1.2. Монокулярные подходы на базе глубокого обучения

Монокулярная оценка глубины (Monocular Depth Estimation) направлена на реконструкцию 3D-структуры по одному 2D-кадру. Поскольку задача математически некорректна (одной проекции соответствует бесконечное множество конфигураций сцены), современные нейросетевые архитектуры

(MiDaS, Depth Anything и др.) опираются на предсказание контекста, используя неявные визуальные признаки: линейную перспективу, окклюзию, плотность текстуры и градиенты света и теней.

Преимущества метода — мгновенная покадровая обработка, инвариантность к динамике сцены и высокая адаптивность. Ограничения — неопределённость масштаба (нейросеть определяет лишь относительный порядок объектов, но не абсолютное расстояние), временная несогласованность при покадровой обработке видео и артефакты геометрии на пустых сценах.

1.2. Сравнительный анализ современных моделей карт глубин

Для выбора оптимального решения в рамках проекта необходимо провести анализ алгоритмов трехмерной реконструкции. Рассматриваются как классические геометрические подходы, так и нейросетевые архитектуры.

1.2.1. Модель COLMAP

Классическая система для построения 3D-моделей по набору кадров. Использует алгоритмы SIFT для поиска ключевых точек, сопоставляет ракурсы и оптимизирует итоговую геометрию [2]. **Преимущества:** высокая точность построения и сохранение реальных масштабов. **Недостатки:** низкая скорость обработки. Не работает с движущимися объектами и однородными поверхностями без текстуры.

1.2.2. Модель DepthNet

DepthNet — одна из первых сверточных нейросетей (CNN), созданная для оценки глубины кадра по одиночному изображению. Построена на стандартных сверточных слоях и многослойных перцептронах [3]. Модель напрямую вычисляет значение глубины для каждого пикселя с помощью функций потерь. **Преимущества:** простая структура, малый размер файла модели и высокая скорость работы даже на слабом оборудовании. **Недостатки:** низкая детализация. Модель размывает границы объектов, теряет мелкие детали на заднем плане и часто ошибается при обработке новых, незнакомых типов сцен.

1.2.3. Модель MiDaS

MiDaS (Monocular Depth Estimation via Robust Remaining Depth) — одна из ключевых нейросетевых моделей, которая установила новый стандарт качества в оценке глубины по одному кадру. Использует комбинацию сверточных слоев и трансформеров. Главное отличие — обучение на разных типах данных (3D-сканы, результаты лазерного сканирования, псевдо-глубина) с применением специальной функции потерь, устойчивой к изменению масштаба и сдвигам [4].

Преимущества: высокая универсальность. Модель стабильно работает на абсолютно незнакомых изображениях и четко разделяет передний, средний и задний планы. **Недостатки:** при обработке видео базовые версии MiDaS вызывают мерцание фона от кадра к кадру. Модель определяет только относительную глубину, а не точные реальные размеры объектов.

1.2.4. Модель Depth Anything v2

Depth Anything v2 — одна из самых современных и точных моделей для оценки глубины по одному кадру, созданная с использованием методов самообучения и дистилляции знаний [5]. Использует мощные визуальные трансформеры. Обучена на огромном объеме данных: около 600 тысяч синтетических изображений с разметкой и более 62 миллионов реальных кадров без разметки [6]. **Преимущества:** высокая детализация и четкость контуров (распознает даже сложные и мелкие объекты: спицы колес, волосы, прозрачные элементы). Выпускается в нескольких версиях разного размера (от легкой Small до тяжелой Large), что позволяет выбирать баланс между скоростью работы и точностью [7]. **Недостатки:** для работы крупных и самых точных версий в реальном времени необходимы мощные современные видеокарты (GPU).

1.2.5. Модель DINOv3

DINOv3 — передовая базовая ИИ-модель от компании Meta, представляющая собой новое поколение самообучающихся визуальных трансформеров [8]. Крупный визуальный трансформер (Vision Transformer),

обученный без ручной разметки и текстовых описаний на 1,7 миллиарда изображений. Использует специальное позиционное кодирование и регистровые токены для стабильной работы механизма внимания. **Преимущества:** формирует высокодетализированные признаки изображений. Обеспечивает высокое качество сегментации объектов и точный анализ структуры сложных сцен. **Недостатки:** требует больших вычислительных мощностей и объема видеопамати. Не создает карту глубин напрямую (нужен отдельный декодер).

1.2.6. Выбор модели для реализации

Исходя из проделанного анализа составим сводную таблицу характеристик модели (таблица 1.1).

Таблица 1.1.

Сравнение характеристик моделей

Критерий	COLMAP	DepthNet	MiDaS	Depth Anything v2	DINOv3
Тип подхода	Геометрич.	Нейронный	Нейронный	Нейронный	Фундаментал.
Входные данные	Серия кадров	Один кадр	Один кадр	Один кадр	Один кадр
Тип глубины	Абсолютная метрическая	Относит.	Относит.	Относит.	Универсал.
Детализация контуров	Высокая	Низкая	Средняя / Высокая	Очень высокая	Очень высокая
Динамические сцены	Нет	Да	Да	Да	Да
Сложность	Высокая	Низкая	Средняя	Средняя	Высокая

По результатам анализа для веб-приложения была выбрана модель Depth Anything v2, показавшая оптимальный баланс точности и скорости. В отличие от ресурсоемких DINOv3 и COLMAP, она работает быстро, а линейка версий (от Small до Large) позволяет легко подстроить систему под мощности сервера. Высокая детализация и четкость контуров минимизируют мерцание фона при обработке видео, что делает Depth Anything v2 лучшим решением для интеграции в веб-интерфейс.

1.3. Обоснование выбора технологического стека

Разработка программного комплекса требует гибкой и платформонезависимой архитектуры. В технологический стек проекта вошли язык Python 3.10, веб-фреймворк Gradio 5.38.0 и среда контейнеризации Docker.

Язык Python 3.10 выбран благодаря развитой экосистеме библиотек машинного обучения и компьютерного зрения (PyTorch, OpenCV). Для быстрого создания интерфейса применяется библиотека Gradio 5.38.0, которая содержит готовые компоненты работы с медиафайлами и не требует привлечения сложных frontend-технологий. Изоляция и переносимость системы обеспечиваются с помощью Docker: упаковка приложения, моделей и зависимостей в единый образ исключает ошибки окружения и упрощает развертывание комплекса на сервере.

ГЛАВА 2. ПРОЕКТИРОВАНИЕ И ПРОГРАММНАЯ РЕАЛИЗАЦИЯ СИСТЕМЫ ПОСТРОЕНИЯ КАРТ ГЛУБИН

2.1. Формулирование требований к веб-приложению и определение его архитектуры

На этапе проектирования были сформулированы ключевые требования к системе и разработана её модульная архитектура. К функциональным требованиям относятся загрузка видео, покадровый расчет карт глубин с помощью ИИ-модели, просмотр результата в реальном времени и возможность его скачивания. Нефункциональные требования задают кроссплатформенность, высокую скорость работы и стабильность интерфейса при обработке крупных файлов.

Архитектура приложения разделена на два компонента: Frontend на Gradio отвечает за взаимодействие с пользователем и отображение медиафайлов, а Backend на Python управляет декодированием видео, инференсом Depth Anything v2 и сборкой итогового ролика. Окружение изолировано с помощью Docker, что обеспечивает быструю и стабильную сборку на любых серверах.

2.2. Разработка веб-приложения и программная реализация модели

Система разработана на Python 3.10 с применением библиотеки PyTorch и фреймворка Gradio 5.38.0. Архитектура приложения состоит из двух модулей: инференса нейросети и веб-интерфейса.

Модуль инференса интегрирует модель Depth Anything v2. Библиотека OpenCV покадрово считывает видео, передает кадры после нормализации в нейросеть, а полученную матрицу глубин преобразует в цветную карту и записывает в итоговый видеофайл. Модуль веб-интерфейса построен на компонентах gr.Blocks(). Он разделен на две зоны: левая колонка (gr.Video()) предназначена для загрузки исходного видео и настроек, а правая — для просмотра и скачивания результата. Нажатие кнопки в интерфейсе запускает процесс покадровой обработки на бэкенде.

2.3. Инженерная отладка и сборка Docker-контейнера

На заключительном этапе проводились отладка модулей, оптимизация вычислительного конвейера и контейнеризация приложения. В процессе отладки была настроена потоковая передача данных между OpenCV и Gradio, что исключило утечки оперативной памяти при обработке длинных видеороликов. Для обеспечения переносимости системы собран Docker-контейнер на базе образа nvidia/cuda с Ubuntu и Python 3.10. Внутри образ содержит все зависимости (PyTorch, Gradio 5.38.0) и проброшенные порты, благодаря чему приложение можно развернуть на любом сервере одной командой.

2.4. Выводы по главе

В ходе производственной практики был успешно реализован программный комплекс для построения карт глубин по видео с использованием искусственного интеллекта. В рамках теоретического этапа проведен анализ методов 3D-реконструкции и монокулярных нейросетей. По его результатам выбрана модель Depth Anything v2, показавшая оптимальный баланс точности,

детализации и скорости работы. На этапе реализации на базе Python 3.10 и Gradio 5.38.0 создано веб-приложение для загрузки, обработки и скачивания готовых видеофайлов. Упаковка проекта в Docker-контейнер обеспечила полную независимость приложения от локального окружения и простоту развертывания на серверах.

ГЛАВА 3. ЭКСПЕРИМЕНТАЛЬНОЕ ИССЛЕДОВАНИЕ И АНАЛИЗ РЕЗУЛЬТАТОВ РАБОТЫ МОДЕЛИ

3.1. Методика проведения экспериментов и метрики оценки

Эксперименты и расчет метрик проводились на локальном узле с процессором **Intel Core i7-8750H** и видеокартой **NVIDIA GeForce GTX 1060 (6 ГБ)**, ресурсы которой задействовались для ускорения инференса нейросети через CUDA.

Тестирование заключалось в обработке видеопотоков разного разрешения и типа сцен, а используемые метрики разделялись на три категории: референсные, безреференсные и программные.

3.1.1. Референсные метрики качества

В первую группу входят такие показатели, как среднеквадратическая ошибка (RMSE), абсолютная относительная разность (REL) и метрика пороговой точности.

Данные метрики являются строго референсными и применяются только в тех сценариях, когда у исследователя имеется в наличии идеальный «эталон» для сравнения. В качестве такого эталона может выступать точное видео с лазерного лидара или глубина сцены, сгенерированная внутри специализированного 3D-редактора. [9]

3.1.2. Безреференсные метрики качества

При отсутствии эталонной геометрии качество карт глубин оценивается безреференсным подходом — на основе анализа структурных характеристик изображения и его временной стабильности [9].

Данный метод опирается на три ключевых параметра. Временная консистентность определяет стабильность карты глубин во времени за счет сравнения соседних кадров и фиксирует отсутствие мерцания на статичных объектах. Контрастность и динамический диапазон оцениваются визуально и отражают степень использования градиента от близких объектов к дальним, исключая слияние диапазона в серый цвет. Четкость границ также проверяется визуально на сложных фрагментах кадра и показывает способность алгоритма сохранять мелкие детали (волосы, провода, углы) без размытия.

3.1.3. Программные метрики

В качестве программной метрики используется индекс структурного сходства (SSIM) из библиотеки scikit-image. В отличие от среднеквадратичной ошибки (MSE), SSIM оценивает восприятие человека за счет локального анализа яркости, контраста и структуры через скользящее окно.

Алгоритм сравнивает блоки эталонного и тестируемого изображений, рассчитывая индекс схожести от 0 до 1 (где 1 — полная идентичность) с последующим усреднением. Это позволяет точнее отражать визуальные искажения (размытие, сжатие, потерю деталей), чем простые пиксельные метрики [10]. В рамках эксперимента значения SSIM интерпретируются согласно таблице 3.1.

Таблица 3.1.

Интерпретация значений метрики SSIM

Диапазон SSIM	Процент сходства	Оценка качества	Значение
0.95 - 1.00	95% - 100%	Отлично	Модели выдают одинаковый контур и стабильность.

0.90 - 0.94	90% - 94%	Хорошо	Базовая геометрия совпадает, но есть мелкие различия.
0.80 - 0.89	80% - 89%	Удовлетворительно	Модель заметно «мылит» картинку.
Ниже 0.80	Ниже 80%	Провал	Карта глубины искажена, ломается геометрия, сильные шумы.

3.2. Анализ влияния конфигураций модели

В данном разделе проводится сравнительный анализ трёх конфигураций модели Depth Anything V2 — **Small**, **Base** и **Large** по двум ключевым критериям: **производительность** (время обработки и потребление ресурсов) и **качество выходных карт глубины**. Целью является определение оптимальной конфигурации, обеспечивающей наилучший баланс между точностью и вычислительными затратами.

Для тестирования было выбрано следующее видео:

- Расширение: .MOV;
- Длительность: 4 секунды;
- Размер: 1,53 МБ;
- Разрешение: 1280x720.

Более подробные характеристики видео можно увидеть на рис. 3.1.

Видео	
Продолжительность	00:00:04
Ширина кадра	720
Высота кадра	1280
Скорость передачи данных	3135 кбит в сек
Общая скорость потока	3205 кбит в сек
Частота кадров	60.17 кадров/с
Аудио	
Скорость потока	69 кбит в сек
Каналы, количество	2 (стерео)
Частота дискретизации	44.100 кГц

Рис. 3.1. Расширенные характеристики анализируемого видео

3.2.1. Анализ производительности

Результаты обработки тестового видео представлены в таблице 3.2.

Таблица 3.2.

Результаты обработки тестового видео

Модель	Загрузка модели (с)	RAM при загрузке (МБ)	VRAM при загрузке (МБ)	Обработка видео (с)	RAM при обработке (МБ)	VRAM при обработке (МБ)
Small	82,32	714,27	94,56	53,98	2730,57	291,02
Base	82,65	713,25	374,40	129,99	2734,29	695,19
Large	85,45	715,12	1281,11	349,10	2693,12	1847,73

На рис. 3.2. представлено сравнение времени загрузки моделей и обработки видео. Время загрузки моделей увеличивается незначительно — от Small к Large прирост составляет всего 3,9%. В то время как время обработки видео демонстрирует существенную разницу: модель Base обрабатывает видео в 2,4 раза дольше, чем Small, а модель Large — уже в 6,5 раз дольше. Таким образом, выбор модели критически влияет на скорость работы приложения, особенно при обработке длительных видеороликов.




Рис. 3.2. Время загрузки и обработки моделей

На рис. 3.3 представлено потребление видеопамати (VRAM) на этапах загрузки модели и обработки видео. При загрузке модели наблюдается значительный рост: Large потребляет в 3,9 раз больше VRAM, чем Small, и в 3,4 раза больше, чем Base. При обработке видео разница также существенна: Large использует в 6,3 раз больше видеопамати, чем Small, и в 2,7 раз больше, чем Base.

Таким образом, выбор модели напрямую определяет требования к видеокарте: Small может работать на устройствах с ограниченным объёмом VRAM, тогда как Large требует наличия мощного GPU с большим запасом памяти.




Рис. 3.3. Потребление VRAM при загрузке и обработке видео

На рис. 3.4. представлено потребление оперативной памяти (RAM) на этапах загрузки модели и обработки видео. В отличие от VRAM, потребление RAM остаётся практически неизменным для всех моделей как при загрузке (~714 МБ), так и при обработке (~2720 МБ). Это объясняется тем, что оперативная память расходуется преимущественно на хранение кадров видео и промежуточных данных, а не на веса модели, которые размещаются в VRAM.




Рис. 3.4. Потребление RAM при загрузке и обработке видео

Таким образом, выбор модели не влияет на требования к объёму RAM, и все три версии могут работать на устройствах с одинаковым объёмом оперативной памяти.

3.2.2. Анализ качества

Возьмем Large за эталон качества и посмотрим, насколько Small и Base от неё отстают. Для выбранного видео получились следующие результаты:

- SSIM Small to Large: 0,9086998955455601;
- SSIM Base to Large: 0,9712196526976168.

Тестирование показало, что модель **Base** демонстрирует отличное качество (~97% сходства с эталоном **Large**), сохраняя детализацию и геометрию карт глубины с минимальными визуальными потерями. Модель **Small** показывает приемлемый результат (~91% сходства) с небольшим размытием, но подходит для задач, где критична скорость обработки.

Таким образом, **Base** является оптимальным выбором для большинства сценариев, обеспечивая баланс качества и производительности. **Large** рекомендуется только при необходимости максимальной точности, а **Small** — когда скорость важнее качества.

3.3. Исследование зависимости эффективности от параметров входного видеопотока

3.3.1. Влияние цветowych карт на скорость обработки

Полный список доступных цветowych карт (ColormapTypes) в OpenCV [11]:
[COLORMAP_AUTUMN, COLORMAP_BONE, COLORMAP_JET,
COLORMAP_WINTER, COLORMAP_RAINBOW, COLORMAP_OCEAN,
COLORMAP_SUMMER, COLORMAP_SPRING, COLORMAP_COOL,
COLORMAP_HSV, COLORMAP_PINK, COLORMAP_HOT,
COLORMAP_PARULA, COLORMAP_MAGMA, COLORMAP_INFERNO,
COLORMAP_PLASMA, COLORMAP_VIRIDIS, COLORMAP_CIVIDIS,
COLORMAP_TWILIGHT, COLORMAP_TWILIGHT_SHIFTED,
COLORMAP_TURBO, COLORMAP_DEEPPGREEN].

По официальной классификации OpenCV данные цвета делятся на 3 типа [11]:

1. Классические (JET, RAINBOW, HOT, COOL, SPRING, SUMMER, ...);
2. Современные (VIRIDIS, PLASMA, MAGMA, INFERNO, ...);
3. Специфические (DEEPPGREEN — для медицинских изображений, HSV — для HSV-представлений, PARULA — для цветовой слепоты, ...).

Примеры спектров цветowych карт можно увидеть на рис. 3.5.


COLORMAP_AUTUMN Python: <code>cv.COLORMAP_AUTUMN</code>	
COLORMAP_BONE Python: <code>cv.COLORMAP_BONE</code>	
COLORMAP_JET Python: <code>cv.COLORMAP_JET</code>	
COLORMAP_WINTER Python: <code>cv.COLORMAP_WINTER</code>	
COLORMAP_RAINBOW Python: <code>cv.COLORMAP_RAINBOW</code>	

Рис. 3.5. Некоторые спектры цветowych карт

Проведем сравнение для двух цветowych карт из каждой категории. Дополнительно возьмем серую (GRAY) цветową карту, работающую только с одним цветowym каналом:

- Классические: JET, RAINBOW;
- Современные: INFERNO, VIRIDIS;
- Специфические: DEEPPGREEN, PARULA;
- Базовый: GRAY.

Сравним по следующим характеристикам: **время обработки** и **использование RAM и VRAM**. Эти данные позволят нам оценить производительность, определить аппаратные требования и возможность работы на различных конфигурациях. Метрику SSIM было принято решение не использовать, поскольку она сравнивает структурное сходство только по одному каналу (grayscale), поэтому SSIM у всех цветowych карт будет одинаковым.

Выберем видеоролик со следующими характеристиками:

- Расширение: .MOV;
- Длительность: 4 секунды;
- Размер: 6,15 МБ;
- Разрешение: 1920x1080.

Более подробные характеристики видео можно увидеть на рис. 3.6.

Видео

Продолжительность	00:00:04
Ширина кадра	1920
Высота кадра	1080
Скорость передачи данных	10326 кбит в сек
Общая скорость потока	10326 кбит в сек
Частота кадров	23.98 кадров/с

Рис. 3.6. Подробные характеристики тестируемого видеоролика

Видео представляет собой ускоренную запись центральной городской площади с неподвижной камеры. Сцена характеризуется статичным фоном и динамическими объектами (пешеходами), что позволяет оценить стабильность построения карт глубины на неизменных участках сцены при наличии движущихся объектов. Кадр из видео можно увидеть на рис. 3.7.




Рис. 3.7. Кадр из тестируемого видеоролика

В результате обработки видеоролика на выбранных цветовых картах получаем следующую таблицу (см. таблицу 3.3). Кадр из обработанного видео с цветовой картой COLORMAP_JET можно увидеть на рис. 3.8.

Таблица 3.3.

Результаты тестирования цветовых карт.

Цветовая карта	Время обработки (с)	RAM (МБ)	VRAM (МБ)
JET	65,69	2761,21	695,19
RAINBOW	65,30	2763,65	695,19
INFERNO	65,42	2764,77	695,19
VIRIDIS	65,53	2762,61	695,19
DEEPPGREEN	65,47	2762,62	695,19
PARULA	65,24	2763,45	695,19
GRAY	65,23	2762,15	695,19




Рис. 3.8. Кадр из обработанного видео с цветовой картой COLORMAP_JET

Исходя из таблицы 3.3, все цветовые карты показали идентичную производительность. Разница во времени обработки — менее 0,5% (от 65,23 до 65,69 секунд). VRAM идентичен для всех тестов (695,19 МБ). RAM колеблется в пределах погрешности (± 3 МБ).

Это объясняется тем, что основная вычислительная нагрузка приходится на работу модели Depth Anything V2 — обработку каждого кадра нейросетью для построения карты глубины. Применение цветовой карты через метод `applyColorMap()` является финальной операцией визуализации, которая выполняется на CPU и представляет собой быстрое табличное преобразование, не требующее значительных вычислительных ресурсов.

Таким образом, выбор цветовой схемы не влияет на производительность и определяется исключительно визуальными предпочтениями и задачами визуализации.

3.3.2. Влияние разрешения и сжатия кадра

Теперь измерим влияние разрешения видеоролика на его обработку. Выберем видеоролик со следующими характеристиками:

- Расширение: .MOV;
- Длительность: 5 секунд;
- Размер файла: 20,8 МБ;
- Разрешение: 3840x2160 (4K).

Более подробные характеристики видео можно увидеть на рис. 3.9.

Видео	
Продолжительность	00:00:05
Ширина кадра	3840
Высота кадра	2160
Скорость передачи данных	29095 кбит в сек
Общая скорость потока	29095 кбит в сек
Частота кадров	23.98 кадров/с

Рис. 3.9. Подробные характеристики тестируемого видеоролика

Видео представляет собой аэросъемку лесного участка дороги с квадрокоптера. Сцена характеризуется динамическим движением камеры и наличием движущихся объектов (автомобилей), что позволяет оценить устойчивость модели к изменению ракурса, расстояния до объектов и наличие движущихся элементов в кадре. Кадр из видео можно увидеть на рис. 3.10.




Рис. 3.10. Кадр из тестируемого видеоролика

При помощи уменьшения разрешения видеоролика было получено 5 копий исходного видео, имеющих разное качество: 1920x1080 (Full HD), 1280x720 (HD), 854x480, 640x360, 428x240.

Сравним их по таким же характеристикам: **время обработки** и **использование RAM и VRAM**. По ранее полученным результатам был сделан вывод, что выбор цветовой карты не влияет на данные характеристики, поэтому выберем одноканальную серую карту (GRAY). После обработки всех копий получился следующий результат (см. таблицу 3.4).

Таблица 3.4.

Результаты обработки видео с разными разрешениями

Разрешение	Время (с)	RAM (МБ)	VRAM (МБ)
428x240	16,71	2680,72	483,64
640x360	17,25	2692,59	483,64
854x480	63,04	2697,43	694,27
1280x720	65,72	2648,67	694,27
1920x1080	70,55	2669,54	694,27
3840x2160	103,49	2747,88	694,27

Из рис. 3.11 мы видим, что время обработки видео растет с увеличением разрешения. Произошло два выраженных скачка — на этапе 480p, и при переходе к 4K.




Рис. 3.11. Зависимость времени обработки от разрешения видео

Рост времени обработки при увеличении разрешения обусловлен квадратичным ростом количества пикселей, что пропорционально повышает вычислительную сложность инференса нейросети. Скачки на 480p и 4K вызваны переходом модели к обработке тензоров большего размера, требующим дополнительных ресурсов и памяти.

Наиболее сбалансированным является разрешение 1920x1080: оно обеспечивают выигрыш по времени в 32% относительно 4K, лишь незначительно уступая по скорости низким разрешениям (480p, 720p). Для максимальной экономии времени подходит 640x360.

Потребление RAM остается практически неизменным для всех разрешений (~2650–2750 МБ), так как оперативная память расходуется преимущественно на хранение кадров и промежуточных данных, объем которых при масштабировании незначителен относительно общего потребления системы (рис. 3.12).




Рис. 3.12. Зависимость оперативной памяти от разрешения видео

Из рис. 3.13 мы видим, что для видеопамати (VRAM) характерна ступенчатая зависимость: при переходе от 360р к 480р происходит скачок с 483,64 МБ до 694,27 МБ, после чего объем памяти стабилизируется и больше не растет. Это объясняется тем, что модель обрабатывает тензоры фиксированного размера, и скачок памяти происходит только при превышении определённого порога разрешения.




Рис. 3.13. Зависимость видеопамати от разрешения видео

Таким образом, при ограниченном объёме видеопамати оптимальным выбором будут разрешения 640x360 и ниже, тогда как при наличии достаточного ресурса GPU можно использовать любой формат от 854x480 до 4K без дополнительного расхода VRAM.

Для оценки структурных потерь при снижении разрешения видео карты глубин сравнивались с помощью метрики SSIM. Эталонное 4K-видео приводилось к разрешению каждого тестового ролика с последующим попарным сравнением кадров.

Это позволило определить, насколько страдают контуры объектов и геометрия сцены. Высокое значение SSIM указывает на минимальные потери информации при уменьшении входного разрешения. Результаты приведены в таблице 3.5.

Таблица 3.5.

Результаты сравнения методом SSIM

Разрешение	SSIM
428x240	0,955
640x360	0,962
854x480	0,980
1280x720	0,985
1920x1080	0,995

Из полученных результатов мы видим, что все тестируемые разрешения показывают высокие значения SSIM (от 0,955 до 0,995), что говорит о сохранении структуры карт глубин.

Даже при разрешении 428x240 сходство с эталоном достигает 95,5%, а визуальные различия между картами минимальны.

Для оценки временной стабильности и выявления эффекта «мерцания» (резких скачков глубин между кадрами) был рассчитан SSIM для соседних кадров внутри каждого разрешения. На низких разрешениях мерцание обычно проявляется сильнее, а показатель SSIM между кадрами снижается. Результаты этого сравнения представлены в таблице 3.6.

Результаты метода SSIM между соседними кадрами.

Разрешение	SSIM
428x240	0,985
640x360	0,986
854x480	0,986
1280x720	0,988
1920x1080	0,990

Анализ временной стабильности показал, что модель Depth Anything v2 демонстрирует высокую устойчивость к мерцанию артефактов глубины на всех исследуемых разрешениях (минимальный показатель SSIM составил 0,9848 для разрешения 240p). Наблюдается маленький монотонный рост временной стабильности при увеличении разрешения входного потока от 240p до 1080p. Это объясняется тем, что при более высоком разрешении сохраняются мелкие пространственно-временные ориентиры (текстуры и границы объектов), что минимизирует флуктуации предсказаний нейросети между соседними кадрами.

3.3.3. Выводы

В ходе исследования установлено, что выбор цветовой карты не влияет на производительность модели, поскольку основная нагрузка приходится на работу нейросети.

Время обработки видео растёт с увеличением разрешения, при этом наблюдаются скачки на 480p и 4K. Потребление RAM стабильно для всех разрешений, а VRAM имеет ступенчатую зависимость.

На основе сопоставления метрики структурного сходства и временных затрат определено, что разрешение 1920x1080 является наиболее оптимальным для практического применения. Оно обеспечивает геометрическую точность на уровне 99,5% и временную стабильность 0,990 по отношению к абсолютному

максимуму, сокращая при этом время обработки на 31,8% по сравнению с разрешением 4K.

3.4. Оценка стабильности модели на различных типах сцен

Для определения пределов применимости модели был проведен стресс-тест на синтетическом видео со статичным белым фоном. Эксперимент показал, что при полном отсутствии текстуры и геометрии модель генерирует артефакты — центральное пятно и виньетирование по краям (рис. 3.14), обусловленные её архитектурными особенностями. При этом значение метрики Temporal SSIM составило 0,9914, что указывает на высокую межкадровую стабильность самих артефактов, но подтверждает критическую зависимость монокулярной оценки от наличия визуальных ориентиров в кадре.




Рис. 3.14. Кадр из результата обработки статичного белого фона

Дополнительно проверено тестирование на длительном видео (37 минут 43 секунды) с динамичной сценой — чайка на фоне воды. Из-за схожести текстур птица периодически сливалась с фоном, что усложняло задачу для алгоритма. Обработка ролика на модели Base заняла 2262,9 секунды, а потребление оперативной и видеопамяти составило 2690,70 МБ (RAM) и 695,19 МБ (VRAM) соответственно. Исходный кадр и полученная карта глубин представлены на рисунках 3.15 и 3.16.



Рис. 3.15 Исходный кадр видеоролика с чайкой




Рис. 3.16. Результат обработки видеоролика с чайкой

Таким образом, модель Depth Anything v2 демонстрирует высокую стабильность на сценах с чёткими текстурами и геометрией, однако на однородных поверхностях возможны артефакты. Длительные видеоролики обрабатываются устойчиво, но требуют значительных временных затрат, что необходимо учитывать при выборе конфигурации модели для практических задач.

ЗАКЛЮЧЕНИЕ

В ходе прохождения производственной практики была полностью достигнута поставленная цель — проведен сравнительный анализ методов построения карт глубин и разработан готовый программный комплекс для автоматической обработки видеопотоков.

В процессе работы были изучены современные методы 3D-реконструкции (DepthNet, Depth Anything v2, DINOv3, COLMAP, MiDaS) и обоснован выбор модели Depth Anything v2. На основе сформулированных требований разработана модульная архитектура и определен технологический стек: Python 3.10, Gradio 5.38.0 и Docker. На этапе реализации создан веб-интерфейс, обеспечивающий загрузку видео, покадровый расчет карт глубин, просмотр в реальном времени и скачивание результата. Интеграция нейросетевого конвейера на базе PyTorch обеспечила точную передачу геометрии кадров. В завершение проведена отладка системы, исключены утечки памяти при работе с длительными роликами и собрана Docker-емкость для платформонезависимого развертывания.

Эксперименты показали, что модель Base является оптимальной конфигурацией (97% сходства с версией Large при ускорении в 2,4 раза), а разрешение 1920×1080 обеспечивает 99,5% точности, сокращая время обработки на 31,8% по сравнению с 4K. Высокие показатели Temporal SSIM (0,985-0,992) подтверждают временную стабильность и отсутствие мерцания кадров.

Таким образом, разработанный и контейнеризированный программный комплекс представляет собой готовое практическое решение, рекомендуемое к внедрению в системы компьютерного зрения, робототехники и видеонаблюдения.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Лебедев О.Б., Черкасов Р.И. Применение технологий компьютерного зрения в системах обработки визуальной информации // Известия Южного федерального университета. Технические науки. — 2025. — № 5. — С. 254-276. — DOI: 10.18522/2311-3103-2025-5-254-276.
2. COLMAP: как превратить обычные фото в точные 3D-модели [Электронный ресурс] // DevTrends. — 2026. — 4 июля. — URL: <https://devtrends.ru/c-plus-plus/colmap-colmap> (дата обращения: 07.07.2026).
3. Алексеев А.А., Окунев М.А. Анализ методов определения абсолютного расстояния до объекта по изображению с одной видеокамеры с использованием нейронных сетей [Электронный ресурс] // CyberLeninka. — URL: <https://cyberleninka.ru/article/n/analiz-metodov-opredeleniya-absolyutnogo-rasstoyaniya-do-obekta-po-izobrazheniyu-s-odnoy-videokamery-s-ispolzovaniem-neyronnyh> (дата обращения: 22.06.2026).
4. MiDaS : robust monocular depth estimation [Электронный ресурс] // GitHub. — URL: <https://github.com/isl-org/MiDaS> (дата обращения: 23.06.2026).
5. Yang L., Kang B., Huang Z., et al. Depth Anything V2 [Электронный ресурс] // arXiv. — 2024. — URL: <https://arxiv.org/abs/2406.09414> (дата обращения: 25.06.2026).
6. Depth Anything V2 : model card [Электронный ресурс] // Luxonis. — URL: <https://models.luxonis.com/luxonis/depth-anything-v2/c5bf9763-d29d-4b10-8642-fbd032236383> (дата обращения: 26.06.2026).
7. Depth Anything V2 : replicate model [Электронный ресурс] // Replicate. — URL: <https://replicate.com/chenxwh/depth-anything-v2> (дата обращения: 26.06.2026).
8. DINOv3 Explained: technical deep dive [Электронный ресурс] // Lightly. — URL: <https://www.lightly.ai/blog/dinov3> (дата обращения: 27.06.2026).

9. Ranftl R., Lasinger K., Hafner D., et al. Towards Robust Monocular Depth Estimation: Mixing Datasets for Zero-shot Cross-dataset Transfer // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2022. — Vol. 44, no. 3. — P. 1623-1637.
10. Birkl R., Wofk D., Müller M. MiDaS v3.1 — A Model Zoo for Robust Monocular Relative Depth Estimation [Электронный ресурс] // arXiv. — 2023. — URL: <https://arxiv.org/abs/2307.14460> (дата обращения: 30.06.2026).
11. OpenCV: colormap module [Электронный ресурс] // OpenCV documentation. — URL: https://docs.opencv.org/5.0/main_modules/imgproc_colormap.html (дата обращения: 06.07.2026).