

Построение карты глубин для загруженного видео

Методы делятся на две категории:

- 1) **Монокулярная оценка глубины** - метод в компьютерном зрении (по одному кадру, ИИ пытается догадаться, что дальше, а что ближе).
- 2) **Фотограмметрия/SfM** (строгий математический расчет по сдвигу пикселей между кадрами).

Что хотим получить на выходе?

- Градиентное видео:
 - чб
 - цветное
- Массив сырых данных (матрица глубин)
- Трёхмерное облако точек (3D-файл .ply, .obj)

Монокулярная оценка глубины

Принцип работы.

Модели анализируют следующие сигналы:

- **Перспектива и размеры** (объекты, удалённые от камеры, кажутся меньше и их контуры сходятся в одной точке на горизонте).
- **Плотность текстуры** (более детальные и насыщенные элементами текстуры участки часто указывают на близость объекта).
- **Перекрытие/окклюзия** (если один объект частично закрывает другой, то первый, скорее всего, ближе)
- **Затенение** (свет, падающий на выпуклые или вогнутые поверхности, создаёт эффект выпуклости или вогнутости, что тоже намекает на глубину)

Сложности.

- **Неопределенность масштаба** (что дальше что ближе - ок, но сложно оценить абсолютные расстояния в метрах/сантиметрах).
- **Сцены со слабой текстурой** (однотонные фоны, гладкие стены) сильно затрудняют оценку.
- **Условия съемки** (плохое освещение, сильные тени, отражающие или прозрачные поверхности, туман или дым).
- **Временная согласованность (Temporal Consistency)**

Где обычно применяют.

- Построение карт окружения.
- Дополненная реальность (AR) для реалистичного размещения виртуальных объектов в реальном мире.
- 3D-моделирование и реконструкция геометрии объектов.
- Медицинская визуализация (камеры).

- Композитинг в видеопроизводстве (VFX), где нужно корректно обрабатывать окклюзии и глубину резкости.

Фотограмметрия/SfM

Фотограмметрия - это технология получения точных измерений и 3D-информации об объектах и сценах на основе кадров.

Structure from Motion (SfM) - один из ключевых алгоритмов в современной фотограмметрии, позволяющий восстанавливать 3D-структуру сцены по серии 2D-изображений с разных ракурсов.

Принцип работы.

Процесс SfM состоит из нескольких последовательных этапов:

- **Сбор данных.** Нужны кадры сцены с разных точек обзора, важно обеспечить достаточное перекрытие между кадрами (обычно 60-80%).
- **Обнаружение и сопоставление признаков.** Алгоритмы находят характерные (ключевые) точки на каждом кадре и сопоставляют их.
- **Оценка положения камеры.** На основе сопоставленных точек вычисляются параметры камеры (положение и ориентация) для каждого кадра (задача *camera pose estimation*).
- **Триангуляция.** Используя известные положения камер и соответствующие точки на изображениях, вычисляются 3D-координаты этих точек методом триангуляции.
- **Bundle Adjustment (оптимизация связки).** Итеративный процесс, который одновременно уточняет 3D-положение точек и параметры камер, минимизируя общую ошибку перепроецирования (*reprojection error*).
- **Построение плотной карты глубины.** На базе разреженного облака точек и параметров камер создаются плотные карты глубины для каждого изображения.
- **Реконструкция поверхности.** Плотные карты глубины объединяются в единое плотное облако точек, из которого строится полигональная 3D-модель (например, методом *Poisson surface reconstruction*).

Сложности.

- **Движение камеры** обязательно.
- **Сцены со слабой текстурой** (однотонные фоны, гладкие стены) плохо поддаются обработке из-за отсутствия характерных точек.
- **Условия съемки** (плохое освещение, сильные тени, отражающие или прозрачные поверхности, туман или дым).

- **Движение объектов.** Наличие движущихся объектов в сцене (люди, машины, деревья на ветру) может привести к артефактам и ошибкам в реконструкции.
- **Вычислительная сложность** (обработка больших наборов данных).
- **Ограничения по перекрытию** (недостаточное перекрытие между кадрами снижает точность и полноту реконструкции).

Где обычно применяют.

- Картография и геодезия.
- Археология.
- Строительство и архитектура. Обмер зданий, BIM-модели.
- Кино и видеоигры.
- Робототехника и автономное вождение. Навигация и построение карт окружения (SLAM).
- Промышленность. Контроль качества, обратный инжиниринг, измерение размеров деталей.
- Криминалистика. Фиксация места происшествия с точной геометрией и масштабом.

Методы

Монокулярная оценка:

MiDaS (Monocular Depth Estimation in the Wild)

- Один из первых методов, поэтому немного устаревший, но всё равно активно используется.
- Стабильно работает на любых изображениях (в комнатах, на улице, в мультфильмах).
- Легкий запуск.

Depth Anything (v2)

- Считается одной из лучших по соотношению скорость/качество на 2026г.
- Версия V2 использует комбинацию синтетических данных и мощных нейросетей-учителей (на базе DINOv2).
- Отличная детализация - модель четко выделяет шерсть животных, прозрачные объекты, спицы велосипеда и сложные текстуры.
- Есть расширение **Video**, которое устраняет главную проблему покадровой обработки - мерцание. Оно делает карту глубины плавной и согласованной во времени (temporally consistent).
- Довольно быстро работает.

DINOv3 depth estimation (AnyDepth и др.)

Сама по себе DINOv3 - это не карта глубин, а «идеальное зрение» (энкодер). Но если прикрутить легкий декодер (например, AnyDepth), получается мощнейший инструмент оценки глубины.

- Один из самых передовых вариантов на 2026 год.
- Отличное пониманием геометрии мира, замечательно видит физику сцены.
- Требует колоссальных ресурсов, однако есть и более компактные ConvNeXt-варианты.

DepthNet

Под этим названием имеются в виду старые сверточные архитектуры (CNN) середины 2010-х годов или специфические встроенные мобильные сетки.

- Сильно проигрывают трансформерам по качеству и точности.
- Используется довольно редко, для встраиваемых автономным систем (телефоны и др.)

Фотограмметрия SfM:

COLMAP

Это не нейросеть. С помощью чистой математики (триангуляции) вычисляет точное положение точек в 3D-пространстве по движению камеры.

- Дает абсолютную, физически точную геометрическую глубину. Никаких галлюцинаций, свойственных ИИ.
- Камера в видео **обязательно должна двигаться** (смещаться вбок/вперед, а не просто крутиться на месте).
- Считает только статичную геометрию (стены, землю, мебель). Расчёт не получится, если в кадре есть движущиеся объекты.
- Очень медленно работает.

Сравнение моделей

Метод	Скорость работы	Качество краев	Стабильность на видео	Метрическая точность	Движение камеры
MiDaS	Высокая	Среднее	Плохая (мерцает)	Нет (относительная)	Нет
Depth Anything (V2)	Высокая	Отличное	Средняя / Отличная (с Video)	Есть отдельные метрические веса	Нет
DINOv3 (AnyDepth)	От средней до низкой	Отличное	Хорошая	Нет (относительная)	Нет
COLMAP	Очень низкая	Зависит от плотности точек	Идеальная	Да (истинная физика)	Нужно
DepthNet (ранние CNN)	Высокая	Низкое (края сильно размыты)	Плохая (сильно мерцает)	Нет (относительная)	Нет

Вопросы

1) Что хотим получить на выходе?

- Градиентное видео:
 - чб
 - цветное
- Массив сырых данных (матрица глубин)
- Трёхмерное облако точек (3D-файл .ply, .obj)

2) Какая версия CUDA будет? для докерфайла. – 12.0

FROM `pytorch/pytorch:2.5.0-cuda12.1-cudnn9-runtime`

ЦВЕТНОЕ:

Small:

[Model Loaded] RAM: 714.97 MB | VRAM Peak: 94.56 MB

[Processing Finished] RAM: 2201.59 MB | VRAM Peak: 290.65 MB

Base:

[Model Loaded] RAM: 735.67 MB | VRAM Peak: 374.40 MB

[Processing Finished] RAM: 2368.11 MB | VRAM Peak: 695.19 MB

Large:

[Model Loaded] RAM: 740.95 MB | VRAM Peak: 1281.11 MB

[Processing Finished] RAM: 2756.17 MB | VRAM Peak: 1847.73 MB

Замеры для разных моделей

Было выбрано короткое видео .MOV на 4 секунды, весом 1.53 МБ

Видео

Продолжительность	00:00:04
Ширина кадра	720
Высота кадра	1280
Скорость передачи данных	3135 кбит в сек
Общая скорость потока	3205 кбит в сек
Частота кадров	60.17 кадров/с

Аудио

Скорость потока	69 кбит в сек
Каналы, количество	2 (стерео)
Частота дискретизации	44.100 кГц

Для чёрно-белой карты глубин:

- Модель Small

Загрузка модели:

82,323 сек (17:56:56,068-17:58:18,391)

RAM: **714.27 MB** | VRAM Peak: **94.56 MB**

Обработка модели:

53,976 сек (17:59:48,325-18:00:42,301)

RAM: **2730.57 MB** | VRAM Peak: **291.02 MB**

- Модель Base

Загрузка модели:

82,650 сек (18:03:49,480-18:05:12,130)

RAM: **713.25 MB** | VRAM Peak: **374.40 MB**

Обработка модели:

129,986 сек (18:05:12,524-18:07:22,510)

RAM: **2734.29 MB** | VRAM Peak: **695.19 MB**

- Модель Large

Загрузка модели:

85,451 сек (18:10:38,803 - 18:12:04,254)

RAM: **715.12 MB** | VRAM Peak: **1281.11 MB**

Обработка модели:

349,102 сек (18:12:04,656-18:17:53,758)

RAM: **2693.12 MB** | VRAM Peak: **1847.73 MB**

Для чайки (Base):

Обработка модели:

2262,900 сек или **37 минут 42,900** сек (19:38:27,144-20:16:10,044)

RAM: **2690.70 MB** | VRAM Peak: **695.19 MB**

Показатель	Small, Base, Large
Время загрузки	Растёт незначительно (+3,9% от Small к Large)
Время обработки	Растёт значительно: Base в 2,4х дольше Small, Large в 6,5х дольше Small
VRAM (загрузка)	Small 95 МБ -> Base 374 МБ -> Large 1281 МБ (рост в 13,5х)
VRAM (обработка)	Small 291 МБ -> Base 695 МБ -> Large 1848 МБ (рост в 6,3х)
RAM (обработка)	стабильно (~2,7 ГБ) на всех этапах обработки

Оценка и сравнение карт глубин

Две категории:

1) **Референсные метрики** - RMSE (Root Mean Squared Error), REL (Absolute Relative Difference), метрика пороговой точности. Используются, когда есть “эталон” (например, видео с лазерного лидара или из 3D-редактора).

2) **Безреференсные метрики**

Поскольку у нас есть только пользовательское видео, а идеального эталона нет, модели оцениваются по структурным критериям и стабильности во времени.

А. Временная консистентность (Temporal Consistency / Flashing).

Включается следующий кадр, объект вообще не двигался, а модель резко поменяла ему яркость (глубину) на пару тонов. В динамике это выглядит как мигание фона.

Как оценивать: Смотреть на статичные объекты (стены, дальний план). У Large модели фон обычно монолитный и стабильный от кадра к кадру, а у Small фон может мигать.

Б. Четкость границ объектов (Edge Preservation)

Маленькие модели склонны размывать границы объектов.

Как оценивать: Посмотреть на тонкие объекты - пальцы рук, волосы, дужки очков, провода или углы мебели. Large модель обычно четко отделяет руку от фона (граница будет резкой), а Small может превратить её в сглаженное пятно.

В. Контрастность и динамический диапазон шкалы

Плохие модели сжимают всю глубину в узкий серый диапазон: и близкий объект, и далекий кажутся логгеру примерно одинаково серыми.

Как оценивать: Хорошая модель использует весь спектр от черного (ультра-близко) до белого (бесконечно далеко). Картинка выглядит контрастной и объемной, отчетливо разделяя передний, средний и задний планы.

Программная проверка (SSIM)

Можно использовать метрику SSIM (Structural Similarity Index) из библиотеки scikit-image. Возьмем Large за эталон качества и посмотрим, насколько Small и Base от неё отстают. SSIM оценивает схожесть структуры, контраста и восприятия картинок человеком.

Диапазон SSIM	Процент сходства	Оценка качества	Что это значит на практике
0.95 – 1.00	95% – 100%	Отлично (Идеально)	Структурные различия незаметны глазу. Модели выдают одинаковый контур и стабильность.
0.90 – 0.94	90% – 94%	Хорошо (Приемлемо)	Базовая геометрия совпадает, но есть мелкие различия: небольшое мерцание фона или легкое размытие краев.
0.80 – 0.89	80% – 89%	Удовлетворительно	Модель заметно «мылит» картинку, теряет мелкие объекты (пальцы, провода) или путает планы.
Ниже 0.80	Ниже 80%	Брак / Провал	Карта глубины искажена, ломается геометрия, сильные шумы.

Для того же видео (4 секунды) получились такие результаты:

SSIM Small to Large: 0.9086998955455601

SSIM Base to Large: 0.9712196526976168

Вывод: стоит оставлять модель Base.