

Содержание

1. ТЕОРЕТИЧЕСКИЕ ОСНОВЫ И АНАЛИЗ МЕТОДОВ ПОСТРОЕНИЯ КАРТ ГЛУБИН ПО ВИДЕОПОТОКУ.....	7
1.1. Постановка задачи трехмерной реконструкции и классификация подходов.....	7
1.2. Метод Structure from Motion (SfM) в задачах фотограмметрии.....	7
1.2.1. Математические принципы и этапы пайплайна SfM.....	7
1.2.2. Область применения и ограничения фотограмметрического подхода.....	7
1.3. Методы монокулярной оценки глубины на базе глубокого обучения.....	7
1.3.1. Визуальные признаки и принципы монокулярного восприятия.....	7
1.3.2. Ключевые проблемы монокулярного подхода.....	7
1.3.3. Практическое применение монокулярных карт глубин.....	8
1.4. Сравнительный анализ современных программных решений и нейросетевых архитектур.....	8
1.4.1. Классические подходы и ранние сверточные модели.....	8
1.4.2. Современные трансформерные архитектуры.....	8
1.4.3. Обобщенное сопоставление характеристик алгоритмов.....	8
Выводы по главе.....	8
Х. Экспериментальное исследование и анализ результатов работы модели.....	8
Х.1. Методика проведения экспериментов и метрики оценки.....	8
Х.1.1. Референсные метрики.....	8
Х.1.2. Безреференсные метрики.....	8
Х.1.3. Программные метрики.....	9
Х.2. Анализ влияния конфигураций модели.....	11
Х.2.1. Анализ производительности.....	11
Х.2.2. Анализ качества.....	14
Х.3. Исследование зависимости эффективности от параметров входного видеопотока.....	14
Х.3.1. Влияние цветowych карт на скорость обработки.....	15
Х.3.2. Влияние разрешения и сжатия кадра.....	16
Х.4. Оценка стабильности модели на различных типах сцен.....	20

Построение карты глубин для загруженного видео

Методы делятся на две категории:

- 1) **Монокулярная оценка глубины** - метод в компьютерном зрении (по одному кадру, ИИ пытается догадаться, что дальше, а что ближе).
- 2) **Фотограмметрия/SfM** (строгий математический расчет по сдвигу пикселей между кадрами).

Монокулярная оценка глубины

Принцип работы.

Модели анализируют следующие сигналы:

- **Перспектива и размеры** (объекты, удалённые от камеры, кажутся меньше и их контуры сходятся в одной точке на горизонте).
- **Плотность текстуры** (более детальные и насыщенные элементами текстуры участки часто указывают на близость объекта).
- **Перекрытие/окклюзия** (если один объект частично закрывает другой, то первый, скорее всего, ближе)
- **Затенение** (свет, падающий на выпуклые или вогнутые поверхности, создаёт эффект выпуклости или вогнутости, что тоже намекает на глубину)

Сложности.

- **Неопределенность масштаба** (что дальше что ближе - ок, но сложно оценить абсолютные расстояния в метрах/сантиметрах).
- **Сцены со слабой текстурой** (однотонные фоны, гладкие стены) сильно затрудняют оценку.
- **Условия съемки** (плохое освещение, сильные тени, отражающие или прозрачные поверхности, туман или дым).
- **Временная согласованность (Temporal Consistency)**

Где обычно применяют.

- Построение карт окружения.
- Дополненная реальность (AR) для реалистичного размещения виртуальных объектов в реальном мире.
- 3D-моделирование и реконструкция геометрии объектов.
- Медицинская визуализация (камеры).
- Композитинг в видеопроизводстве (VFX), где нужно корректно обрабатывать окклюзии и глубину резкости.

Фотограмметрия/SfM

Фотограмметрия - это технология получения точных измерений и 3D-информации об объектах и сценах на основе кадров.

Structure from Motion (SfM) - один из ключевых алгоритмов в современной фотограмметрии, позволяющий восстанавливать 3D-структуру сцены по серии 2D-изображений с разных ракурсов.

Принцип работы.

Процесс SfM состоит из нескольких последовательных этапов:

- **Сбор данных.** Нужны кадры сцены с разных точек обзора, важно обеспечить достаточное перекрытие между кадрами (обычно 60-80%).
- **Обнаружение и сопоставление признаков.** Алгоритмы находят характерные (ключевые) точки на каждом кадре и сопоставляют их.
- **Оценка положения камеры.** На основе сопоставленных точек вычисляются параметры камеры (положение и ориентация) для каждого кадра (задача *camera pose estimation*).
- **Триангуляция.** Используя известные положения камер и соответствующие точки на изображениях, вычисляются 3D-координаты этих точек методом триангуляции.
- **Bundle Adjustment (оптимизация связки).** Итеративный процесс, который одновременно уточняет 3D-положение точек и параметры камер, минимизируя общую ошибку перепроецирования (*reprojection error*).
- **Построение плотной карты глубины.** На базе разреженного облака точек и параметров камер создаются плотные карты глубины для каждого изображения.
- **Реконструкция поверхности.** Плотные карты глубины объединяются в единое плотное облако точек, из которого строится полигональная 3D-модель (например, методом *Poisson surface reconstruction*).

Сложности.

- **Движение камеры** обязательно.
- **Сцены со слабой текстурой** (однотонные фоны, гладкие стены) плохо поддаются обработке из-за отсутствия характерных точек.
- **Условия съемки** (плохое освещение, сильные тени, отражающие или прозрачные поверхности, туман или дым).
- **Движение объектов.** Наличие движущихся объектов в сцене (люди, машины, деревья на ветру) может привести к артефактам и ошибкам в реконструкции.
- **Вычислительная сложность** (обработка больших наборов данных).
- **Ограничения по перекрытию** (недостаточное перекрытие между кадрами снижает точность и полноту реконструкции).

Где обычно применяют.

- Картография и геодезия.
- Археология.
- Строительство и архитектура. Обмер зданий, BIM-модели.
- Кино и видеоигры.
- Робототехника и автономное вождение. Навигация и построение карт окружения (SLAM).
- Промышленность. Контроль качества, обратный инжиниринг, измерение размеров деталей.
- Криминалистика. Фиксация места происшествия с точной геометрией и масштабом.

Методы

Монокулярная оценка:

MiDaS (Monocular Depth Estimation in the Wild)

- Один из первых методов, поэтому немного устаревший, но всё равно активно используется.
- Стабильно работает на любых изображениях (в комнатах, на улице, в мультфильмах).
- Легкий запуск.

Depth Anything (v2)

- Считается одной из лучших по соотношению скорость/качество на 2026г.
- Версия V2 использует комбинацию синтетических данных и мощных нейросетей-учителей (на базе DINOv2).
- Отличная детализация - модель четко выделяет шерсть животных, прозрачные объекты, спицы велосипеда и сложные текстуры.
- Есть расширение **Video**, которое устраняет главную проблему покадровой обработки - мерцание. Оно делает карту глубины плавной и согласованной во времени (temporally consistent).
- Довольно быстро работает.

DINOv3 depth estimation (AnyDepth и др.)

Сама по себе DINOv3 - это не карта глубин, а «идеальное зрение» (энкодер). Но если прикрутить легкий декодер (например, AnyDepth), получается мощнейший инструмент оценки глубины.

- Один из самых передовых вариантов на 2026 год.
- Отличное пониманием геометрии мира, замечательно видит физику сцены.
- Требует колоссальных ресурсов, однако есть и более компактные ConvNeXt-варианты.

DepthNet

Под этим названием имеются в виду старые сверточные архитектуры (CNN) середины 2010-х годов или специфические встроенные мобильные сетки.

- Сильно проигрывают трансформерам по качеству и точности.
- Используется довольно редко, для встраиваемых автономным систем (телефоны и др.)

Фотограмметрия SfM:

COLMAP

Это не нейросеть. С помощью чистой математики (триангуляции) вычисляет точное положение точек в 3D-пространстве по движению камеры.

- Дает абсолютную, физически точную геометрическую глубину. Никаких галлюцинаций, свойственных ИИ.
- Камера в видео **обязательно должна двигаться** (смещаться вбок/вперед, а не просто крутиться на месте).
- Считает только статичную геометрию (стены, землю, мебель). Расчёт не получится, если в кадре есть движущиеся объекты.
- Очень медленно работает.

Сравнение моделей

Метод	Скорость работы	Качество краев	Стабильность на видео	Метрическая точность	Движение камеры
MiDaS	Высокая	Среднее	Плохая (мерцает)	Нет (относительная)	Нет
Depth Anything (V2)	Высокая	Отличное	Средняя / Отличная (с Video)	Есть отдельные метрические веса	Нет
DINOv3 (AnyDepth)	От средней до низкой	Отличное	Хорошая	Нет (относительная)	Нет
COLMAP	Очень низкая	Зависит от плотности точек	Идеальная	Да (истинная физика)	Нужно
DepthNet (ранние CNN)	Высокая	Низкое (края сильно размыты)	Плохая (сильно мерцает)	Нет (относительная)	Нет

1. ТЕОРЕТИЧЕСКИЕ ОСНОВЫ И АНАЛИЗ МЕТОДОВ ПОСТРОЕНИЯ КАРТ ГЛУБИН ПО ВИДЕОПОТОКУ

1.1. Постановка задачи трехмерной реконструкции и классификация подходов

(Введение в проблему, разделение методов на монокулярные и многоракурсные/SfM).

1.2. Метод Structure from Motion (SfM) в задачах фотограмметрии

1.2.1. Математические принципы и этапы пайплайна SfM

(Сбор, сопоставление признаков, триангуляция, Bundle Adjustment).

Добавить описание матрицы камеры и эпиполярной геометрии?

пару абзацев о том, что сопоставление точек между кадрами опирается на фундаментальную матрицу (F) или существенную матрицу (E), а Bundle Adjustment минимизирует функционал ошибки перепроецирования:

$$\min_{P_i, X_j} \sum_{i,j} d^2(x_{ij}, P_i X_j)$$

Где P_i — параметры камеры, X_j — 3D-точка, а x_{ij} — её проекция на кадр.

1.2.2. Область применения и ограничения фотограмметрического подхода

1.3. Методы монокулярной оценки глубины на базе глубокого обучения

1.3.1. Визуальные признаки и принципы монокулярного восприятия

(Перспектива, окклюзии, текстура, затенение).

1.3.2. Ключевые проблемы монокулярного подхода

(Неопределенность масштаба, временная согласованность).

1.3.3. Практическое применение монокулярных карт глубин

1.4. Сравнительный анализ современных программных решений и нейросетевых архитектур

1.4.1. Классические подходы и ранние сверточные модели

(COLMAP, DepthNet)

1.4.2. Современные трансформерные архитектуры

(MiDaS, Depth Anything v2, DINOv3).

Расписать про концепцию Midas-style предобучения и стратегию Data Scale-up.

Смысл в том, что авторы Depth Anything v2 обучили модель на колоссальном объеме неразмеченных реальных картинок, используя псевдо-разметку (data distillation) от мощного «учителя». А DINOv2 используется как замороженный энкодер, потому что он из коробки шикарно понимает семантику и границы объектов.

1.4.3. Обобщенное сопоставление характеристик алгоритмов

(сравнительная таблица).

Выводы по главе

(краткий итог: почему выбрана именно Depth Anything v2).

Таким образом, классические методы (COLMAP) не применимы для динамических сцен с движущимися объектами и требуют высокой вычислительной мощности. Среди монокулярных подходов модель Depth Anything v2 предоставляет наилучший баланс скорости и качества проработки краев, а её модификация Video решает проблему временной нестабильности. На основании проведенного анализа для дальнейшей программной реализации и экспериментальной оценки была выбрана архитектура Depth Anything v2.

Х. Экспериментальное исследование и анализ результатов работы модели

Х.1. Методика проведения экспериментов и метрики оценки

(на каком железе всё запускалось, в двух словах что такое SSIM и Temporal SSIM, которые используются для оценок).

Есть две категории: референсные и безреференсные. Программные метрики.

Х.1.1. Референсные метрики

Референсные метрики - RMSE (Root Mean Squared Error), REL (Absolute Relative Difference), метрика пороговой точности. Используются, когда есть “эталон” (например, видео с лазерного лидара или из 3D-редактора).

Х.1.2. Безреференсные метрики

Безреференсные метрики

Поскольку у нас есть только пользовательское видео, а идеального эталона нет, модели оцениваются по структурным критериям и стабильности во времени.

А. Временная консистентность (Temporal Consistency / Flashing).

Включается следующий кадр, объект вообще не двигался, а модель резко поменяла ему яркость (глубину) на пару тонов. В динамике это выглядит как мигание фона.

Как оценивать: Смотреть на статичные объекты (стены, дальний план). У Large модели фон обычно монолитный и стабильный от кадра к кадру, а у Small фон может мигать.

Б. Четкость границ объектов (Edge Preservation)

Маленькие модели склонны размывать границы объектов.

Как оценивать: Посмотреть на тонкие объекты - пальцы рук, волосы, дужки очков, провода или углы мебели. Large модель обычно четко отделяет руку от фона (граница будет резкой), а Small может превратить её в сглаженное пятно.

В. Контрастность и динамический диапазон шкалы

Плохие модели сжимают всю глубину в узкий серый диапазон: и близкий объект, и далекий кажутся логгеру примерно одинаково серыми.

Как оценивать: Хорошая модель использует весь спектр от черного (ультра-близко) до белого (бесконечно далеко). Картинка выглядит контрастной и объемной, отчетливо разделяя передний, средний и задний планы.

Х.1.3. Программные метрики

Можно использовать метрику SSIM (Structural Similarity Index) из библиотеки scikit-image. **Метрика SSIM** - это алгоритм оценки качества изображений, который моделирует восприятие человека, а не просто

попиксельно сравнивает картинки. В отличие от MSE (среднеквадратичной ошибки), SSIM анализирует три ключевых компонента: яркость, контраст и структуру, вычисляя их на локальных участках изображения с помощью скользящего окна. Алгоритм сравнивает соответствующие блоки эталонного и тестируемого изображений, рассчитывая для каждого блока индекс схожести от 0 до 1, где 1 означает полную идентичность. Итоговое значение SSIM получается усреднением всех локальных индексов, что дает интегральную оценку качества, близкую к субъективному восприятию человеком. Благодаря такому подходу SSIM лучше отражает реальные визуальные искажения, такие как размытие, сжатие или потерю деталей, чем традиционные метрики на основе пиксельных ошибок.

Диапазон SSIM	Процент сходства	Оценка качества	Что это значит на практике
0.95 – 1.00	95% – 100%	Отлично (Идеально)	Структурные различия незаметны глазу. Модели выдают одинаковый контур и стабильность.
0.90 – 0.94	90% – 94%	Хорошо (Приемлемо)	Базовая геометрия совпадает, но есть мелкие различия: небольшое мерцание фона или легкое размытие краев.
0.80 – 0.89	80% – 89%	Удовлетворительно	Модель заметно «мылит» картинку, теряет мелкие объекты (пальцы, провода) или путает планы.
Ниже 0.80	Ниже 80%	Брак / Провал	Карта глубины искажена, ломается геометрия, сильные шумы.

Х.2. Анализ влияния конфигураций модели

В данном разделе проводится сравнительный анализ трёх конфигураций модели Depth Anything V2 - **Small**, **Base** и **Large** по двум ключевым критериям: **производительность** (время обработки и потребление ресурсов) и **качество выходных карт глубины**. Целью является определение оптимальной конфигурации, обеспечивающей наилучший баланс между точностью и вычислительными затратами.

Для тестирования было выбрано следующее видео:

- Расширение: .MOV
- Длительность: 4 секунды
- Вес: 1.53 МБ
- Разрешение: 1280x720

Более подробные характеристики видео можно увидеть на рис. 0.

Видео	
Продолжительность	00:00:04
Ширина кадра	720
Высота кадра	1280
Скорость передачи данных	3135 кбит в сек
Общая скорость потока	3205 кбит в сек
Частота кадров	60.17 кадров/с
Аудио	
Скорость потока	69 кбит в сек
Каналы, количество	2 (стерео)
Частота дискретизации	44.100 кГц

Рис. 0. Расширенные характеристики анализируемого видео

Х.2.1. Анализ производительности

Результаты обработки тестового видеоролика представлены в таблице 0.

Таблица 0. Результаты обработки тестового видеоролика

Модель	Загрузка модели (с)	RAM при загрузке (МБ)	VRAM при загрузке (МБ)	Обработка видео (с)	RAM при обработке (МБ)	VRAM при обработке (МБ)
Small	82.32	714.27	94.56	53.98	2730.57	291.02
Base	82.65	713.25	374.40	129.99	2734.29	695.19
Large	85.45	715.12	1281.11	349.10	2693.12	1847.73

На рис. 0 представлено сравнение времени загрузки моделей и обработки видео. Время загрузки моделей увеличивается незначительно - от Small к Large прирост составляет всего 3.9%. В то время как время обработки видео демонстрирует существенную разницу: модель Base обрабатывает видео в 2,4 раза дольше, чем Small, а модель Large - уже в 6,5 раз дольше. Таким образом, выбор модели критически влияет на скорость работы приложения, особенно при обработке длительных видеороликов.




Рис. 0. Время загрузки и обработки моделей

На рис. 0 представлено потребление видеопамати (VRAM) на этапах загрузки модели и обработки видео. При загрузке модели наблюдается значительный рост: Large потребляет в 3,9 раз больше VRAM, чем Small, и в 3,4 раза больше, чем Base. При обработке видео разница также существенна: Large использует в 6,3 раз больше видеопамати, чем Small, и в 2,7 раз больше, чем Base. Таким образом, выбор модели напрямую определяет требования к видеокарте: Small может работать на устройствах с ограниченным объёмом VRAM, тогда как Large требует наличия мощного GPU с большим запасом памяти.




Рис. 0. Потребление VRAM при загрузке и обработке видео




Рис. 0. Потребление RAM при загрузке и обработке видео

На рис. 0 представлено потребление оперативной памяти (RAM) на этапах загрузки модели и обработки видео. В отличие от VRAM, потребление RAM остаётся практически неизменным для всех моделей как при загрузке

(~714 МБ), так и при обработке (~2720 МБ). Это объясняется тем, что оперативная память расходуется преимущественно на хранение кадров видео и промежуточных данных, а не на веса модели, которые размещаются в VRAM. Таким образом, выбор модели не влияет на требования к объёму RAM, и все три версии могут работать на устройствах с одинаковым объёмом оперативной памяти.

Для чайки (Base):

Обработка модели:

2262,900 сек или 37 минут 42,900 сек (19:38:27,144-20:16:10,044)

RAM: 2690.70 MB | VRAM Peak: 695.19 MB

Х.2.2. Анализ качества

Возьмем Large за эталон качества и посмотрим, насколько Small и Base от неё отстают. Для того же видео (4 секунды) получились такие результаты:

```
SSIM Small to Large: 0.9086998955455601  
SSIM Base to Large: 0.9712196526976168
```

Тестирование показало, что модель **Base** демонстрирует отличное качество (SSIM = 0.971, 97% сходства с эталоном **Large**), сохраняя детализацию и геометрию карт глубины с минимальными визуальными потерями. Модель **Small** показывает приемлемый результат (SSIM = 0.909, 91% сходства) с небольшим размытием, но подходит для задач, где критична скорость обработки.

Таким образом, **Base** является оптимальным выбором для большинства сценариев, обеспечивая баланс качества и производительности. **Large** рекомендуется только при необходимости максимальной точности, а **Small** - когда скорость важнее качества.

Х.3. Исследование зависимости эффективности от параметров входного видеопотока

(все тесты, где крутим настройки самого видео)

Х.3.1. Влияние цветowych карт на скорость обработки

Полный список доступных цветowych карт (ColormapTypes) в OpenCV:

[COLORMAP_AUTUMN, COLORMAP_BONE, COLORMAP_JET,
COLORMAP_WINTER, COLORMAP_RAINBOW, COLORMAP_OCEAN,
COLORMAP_SUMMER, COLORMAP_SPRING, COLORMAP_COOL,
COLORMAP_HSV, COLORMAP_PINK, COLORMAP_HOT, COLORMAP_PARULA,
COLORMAP_MAGMA, COLORMAP_INFERNO, COLORMAP_PLASMA,
COLORMAP_VIRIDIS, COLORMAP_CIVIDIS, COLORMAP_TWILIGHT,
COLORMAP_TWILIGHT_SHIFTED, COLORMAP_TURBO,
COLORMAP_DEEPPGREEN]

По официальной классификации OpenCV данные цвета делятся на 3 типа:

1. Классические (JET, RAINBOW, HOT, COOL, SPRING, SUMMER, AUTUMN, WINTER, BONE, PINK, OCEAN)
2. Современные (VIRIDIS, PLASMA, MAGMA, INFERNO, CIVIDIS, TURBO)
3. Специфические (DEEPPGREEN - для медицинских изображений, HSV - для HSV-представлений, PARULA - для цветовой слепоты)

Проведем сравнение для двух видов из каждой категории, а также вариант без цвета (ч/б - GRAY):

- Классические: JET, RAINBOW
- Современные: INFERNO, VIRIDIS
- Специфические: DEEPPGREEN, PARULA
- Базовый: GRAY

Сравним по следующим характеристикам:

Время обработки - оценивает производительность и пригодность для использования в веб-приложении.

Использование RAM и VRAM - определяет аппаратные требования и возможность работы на различных конфигурациях.

Метрику SSIM было принято решение не использовать, поскольку она сравнивает структурное сходство только по одному каналу (grayscale), поэтому SSIM у всех цветных карт будет одинаковый.

Выберем следующее видео (people):

Видео

Продолжительность	00:00:04
Ширина кадра	1920
Высота кадра	1080
Скорость передачи данных	10326 кбит в сек
Общая скорость потока	10326 кбит в сек
Частота кадров	23.98 кадров/с

Результаты:

Цветовая карта	Время обработки (с)	RAM (МБ)	VRAM (МБ)
JET	65.69	2761.21	695.19
RAINBOW	65.30	2763.65	695.19
INFERNO	65.42	2764.77	695.19
VIRIDIS	65.53	2762.61	695.19
DEEPPGREEN	65.47	2762.62	695.19
PARULA	65.24	2763.45	695.19
GRAY	65.23	2762.15	695.19

Все цветовые карты показали идентичную производительность. Разница во времени обработки - менее 0.5% (от 65.23 до 65.69 секунд). VRAM идентичен для всех тестов (695.19 МБ). RAM колеблется в пределах погрешности (± 3 МБ)

VRAM одинаков, потому что цветовые карты применяются на CPU и не влияют на видеопамять. RAM колеблется незначительно - в пределах погрешности измерений. Цветовые карты применяются на CPU (через OpenCV), поэтому они не влияют на VRAM. Вся нагрузка на видеокарту связана исключительно с работой модели Depth Anything V2.

Таким образом, выбор цветовой карты не влияет на производительность и определяется исключительно визуальными предпочтениями и задачами визуализации.

Х.3.2. Влияние разрешения и сжатия кадра

Был взят видеоролик, длиной 5 секунд, имеющий качество 4K (3840x2160):

Видео

Продолжительность	00:00:05
Ширина кадра	3840
Высота кадра	2160
Скорость передачи данных	29095 кбит в сек
Общая скорость потока	29095 кбит в сек
Частота кадров	23.98 кадров/с

При помощи сжатия было получено 6 копий исходного видео, имеющих разное качество:

- 3840x2160 (4K)
- 1920x1080 (Full HD)
- 1280x720 (HD)
- 854x480
- 640x360
- 428x240

После обработки всех копий получился следующий результат:

Разрешение	Время (с)	RAM (МБ)	VRAM (МБ)
428x240	16.71	2680.72	483.64
640x360	17.25	2692.59	483.64
854x480	63.04	2697.43	694.27
1280x720	65.72	2648.67	694.27
1920x1080	70.55	2669.54	694.27
3840x2160	103.49	2747.88	694.27




Рис. 0. Зависимость времени обработки от разрешения видео

Из рис. 0 мы видим, что время обработки видео растет с увеличением разрешения. Произошло два выраженных скачка - на этапе 480p, и при

переходе к 4K. В промежутках между этими скачками время обработки остается практически неизменным, что делает разрешение 1920x1080 наиболее выгодным компромиссом для экономии 32% времени по сравнению с 4K.




Рис. 0. Зависимость оперативной памяти от разрешения видео

Из рис. 0 мы видим, что потребление оперативной памяти (RAM) остается стабильным практически на всех этапах, колеблясь в узком диапазоне около 2650-2700 МБ. Единственный выраженный скачок зафиксирован при переходе к разрешению 4K, где показатель достигает своего пика в 2747,88 МБ. В промежутках между низкими и высокими разрешениями объем используемой RAM практически не меняется, что подтверждает слабую зависимость данного ресурса от размера входного видео.




Рис. 0. Зависимость видеопамати от разрешения видео

Из рис. 0 мы видим, что для видеопамати (VRAM) характерна ступенчатая зависимость: при переходе от 360р к 480р происходит скачок с 483,64 МБ до 694,27 МБ, после чего объем памяти стабилизируется и больше не растет. Данный паттерн указывает на внутренние архитектурные особенности модели (разбиение на фиксированные патчи), что защищает GPU от квадратичного роста затрат памяти на сверхвысоких разрешениях.

Для сравнения карт глубины при различных разрешениях видео SSIM применяется следующим образом:

Сравним карты глубин с разными разрешениями видео с помощью метода SSIM. Эталонное видео в разрешении 4K приводится к разрешению каждого тестируемого видео, после чего попарно сравниваются соответствующие кадры. Это позволяет оценить, какие структурные потери возникают при снижении разрешения, насколько страдают контуры объектов, границы переходов и общая геометрия сцены. Чем выше SSIM, тем ближе карта глубины к эталону и тем меньше информации теряется при уменьшении разрешения видео на входе модели.

Разрешение	SSIM
428x240	0.955
640x360	0.962
854x480	0.980
1280x720	0.985
1920x1080	0.995

Из полученных результатов мы видим, что все тестируемые разрешения показывают высокие значения SSIM (от 0.955 до 0.995), что говорит о хорошем сохранении структуры карт глубины даже на низких разрешениях.

Даже самое низкое разрешение (428x240) демонстрирует 95.5% структурного сходства с эталоном, что является отличным результатом. Ожидаемое снижение качества при уменьшении разрешения выражено слабо, и визуальные различия между картами глубины всех разрешений минимальны.

Теперь посчитаем SSIM между соседними кадрами внутри одного и того же разрешения (temporal stability). В видео-глубине часто бывает проблема "мерцания" (flickering), когда от кадра к кадру глубина резко прыгает. Сравнение соседних кадров покажет, при каком разрешении глубина более стабильна во времени. Как правило, на низких разрешениях мерцание выше, а SSIM между соседними кадрами ниже.

Разрешение	SSIM
428x240	0.985
640x360	0.986

854x480	0.986
1280x720	0.988
1920x1080	0.990

Анализ временной стабильности показал, что модель Depth Anything v2 демонстрирует высокую устойчивость к мерцанию артефактов глубины на всех исследуемых разрешениях (минимальный показатель SSIM составил 0.9848 для разрешения 240p). Наблюдается маленький монотонный рост временной стабильности при увеличении разрешения входного потока от 240p до 1080p. Это объясняется тем, что при более высоком разрешении сохраняются мелкие пространственно-временные ориентиры (текстуры и границы объектов), что минимизирует флуктуации предсказаний нейросети между соседними кадрами.

ВЫВОД:

На основе сопоставления метрики структурного сходства и временных затрат определено, что разрешение 1920x1080 является наиболее оптимальным для практического применения. Оно обеспечивает геометрическую точность на уровне 99.5% и временную стабильность 0.990 по отношению к абсолютному максимуму, сокращая при этом время обработки на 31.8% по сравнению с разрешением 4K.

Х.4. Оценка стабильности модели на различных типах сцен

(Результаты теста на Temporal SSIM. Вывод о том, как модель справляется с быстрым движением и мерцанием).

Для определения пределов применимости модели был проведен стресс-тест на синтетическом видеопотоке без пространственных ориентиров (статичный абсолютно белый фон). Эксперимент показал, что при полном отсутствии текстуры и геометрии модель склонна к генерации артефактов (галлюцинации центрального пятна и краевой виньетки, см. рис. 0), обусловленных её внутренними архитектурными паттернами. При этом метрика Temporal SSIM составила 0.9914, что указывает на высокую межкадровую стабильность самих артефактов, но подтверждает критическую зависимость монокулярной оценки от наличия визуальных признаков в кадре.




Рис. 0. Кадр из результата обработки статичного белого фона